

UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA

PROGRAMA DE PÓS-GRADUAÇÃO EM MODELAGEM E MÉTODOS QUANTITATIVOS

MESTRADO ACADÊMICO EM MODELAGEM E MÉTODOS QUANTITATIVOS

PAULA ANDRESSA NASCIMENTO LUCAS

PROBLEMA DE DIMENSIONAMENTO DE LOTES COM RETORNO: PROGRAMAÇÃO DINÂMICA, DIAGRAMA DE DECISÕES E HEURÍSTICAS

FORTALEZA

2026

PAULA ANDRESSA NASCIMENTO LUCAS

PROBLEMA DE DIMENSIONAMENTO DE LOTES COM RETORNO: PROGRAMAÇÃO DINÂMICA, DIAGRAMA DE DECISÕES E HEURÍSTICAS

Proposta de qualificacao apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos da Universidade Federal do Ceará (UFC) como requisito parcial para a defesa de dissertação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Jesus Ossian da Cunha Silva (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Albert Einstein Fernandes Muritiba
Universidade Federal do Ceará (UFC)

Prof. Dr. Wladimir Araújo Tavares
Universidade Federal do Ceará (UFC)

PAULA ANDRESSA NASCIMENTO LUCAS

PROBLEMA DE DIMENSIONAMENTO DE LOTES COM RETORNO: PROGRAMAÇÃO DINÂMICA, DIAGRAMA DE DECISÕES E HEURÍSTICAS

Proposta de qualificacao apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos da Universidade Federal do Ceará (UFC) como requisito parcial para a defesa de dissertação.
Orientador: Prof. Dr. Jesus Ossian da Cunha Silva

FORTALEZA

2026

RESUMO

O Problema de Dimensionamento de Lotes com Retorno (PDLR) surge em diversos contextos industriais que incorporam logística reversa e reaproveitamento de produtos retornados. Trata-se de uma extensão do modelo clássico de dimensionamento de lotes por Wagner e Whitin (1958), incorporando decisões relacionadas à produção, estoque, retorno e remanufatura. Devido à sua elevada complexidade computacional, a resolução exata do PDLR por meio de formulações de Programação Linear Inteira Mista, conforme discutido por Pochet e Wolsey (2006), torna-se desafiadora para instâncias de grande porte. Nesse contexto, este projeto propõe investigar e comparar diferentes estratégias de solução, incluindo heurísticas Relax-and-Fix e Fix-and-Optimize, Programação Dinâmica e Diagramas de Decisão para Otimização. A metodologia envolve a implementação computacional dos métodos e a realização de testes em conjuntos de instâncias da literatura. A avaliação será baseada em métricas como valor da função objetivo, tempo computacional e gap de otimalidade. Espera-se identificar as vantagens e limitações de cada abordagem, bem como analisar cenários em que métodos heurísticos ou baseados em diagramas possam complementar ou superar formulações MILP tradicionais.

Palavras-chave: Dimensionamento de Lotes; Retorno; Heurísticas; Programação Dinâmica; Diagramas de Decisão.

ABSTRACT

The Lot Sizing Problem with Returns (PDLR) arises in several industrial contexts that incorporate reverse logistics and the reuse of returned products. It is an extension of the classical lot sizing model proposed by Wagner e Whitin (1958), incorporating decisions related to production, inventory, returns, and remanufacturing. Due to its high computational complexity, the exact solution of the PDLR through Mixed-Integer Linear Programming (MILP) formulations, as discussed by Pochet e Wolsey (2006), becomes challenging for large-scale instances. In this context, this project proposes to investigate and compare different solution strategies, including Relax-and-Fix and Fix-and-Optimize heuristics, Dynamic Programming, and Decision Diagrams for Optimization. The methodology involves the computational implementation of the proposed methods and computational experiments on benchmark instances from the literature. The evaluation will be based on metrics such as objective function value, computational time, and optimality gap. The goal is to identify the advantages and limitations of each approach, as well as to analyze scenarios in which heuristic or diagram-based methods may complement or outperform traditional MILP formulations.

Keywords: : Lot Sizing; Returns; Heuristics; Dynamic Programming; Decision Diagrams.

LISTA DE ILUSTRAÇÕES

Figura 1 – Rede de conservação de fluxo do PDLR 19
Figura 2 – Exemplo de funcionamento do RF. 31
Figura 3 – Exemplo de funcionamento FOP. 33

LISTA DE ALGORITMOS

Algoritmo 1 – Programação Dinâmica para o PDLR 26
Algoritmo 2 – Diagramas de Decisão para o PDLR 29
Algoritmo 3 – Geração de Partições 32
Algoritmo 4 – Subproblema Relax and Fix 32
Algoritmo 5 – Subproblema Fix and Optimize 34
Algoritmo 6 – Fix-and-Optimize 34

LISTA DE ABREVIATURAS E SIGLAS

B&B	Branch-and-Bound.
CPU	Unidade Central de Processamento.
DD	Diagrama de Decisão.
DDO	Diagrama de Decisão para Otimização.
FO	Fix-and-Optimize.
GAP	Desvio relativo percentual.
MILP	Programação Linear Inteira Mista.
PD	Programação Dinâmica.
PDL	Problema de Dimensionamento de Lotes.
PDLR	Problema de Dimensionamento de Lotes com Retorno.
RF	Relax-and-Fix.

SUMÁRIO

1	**INTRODUÇÃO**	10
1.1	**Considerações Iniciais**	10
1.2	**Relevância e Justificativa**	11
1.3	**Objetivos**	12
1.4	**Organização do trabalho**	12
2	**REVISÃO DE LITERATURA**	13
2.1	**Estrutura e Evolução do Problema de Dimensionamento de Lotes com Retorno**	13
2.2	**Paradigmas de Modelagem e Métodos de Solução**	14
2.3	**Síntese e Análise de Literatura**	16
3	**DESCRIÇÃO DO PROBLEMA**	18
3.1	**Problema de Dimensionamento de Lotes com Retorno (PDLR)**	18
3.2	**Formulação via Programação Linear Inteira Mista (MILP)**	20
4	**ALGORITMOS PARA RESOLVER O PDLR**	23
4.1	**Programação Dinâmica (PD)**	23
4.2	**Diagrama de Decisão para Otimização (DDO)**	27
4.3	**Matheurísticas**	30
5	**EXPERIMENTOS COMPUTACIONAIS**	35
5.1	**Instâncias**	35
5.2	**Ambiente Computacional**	36
5.3	**Métricas de Avaliação**	36
6	**CONTRIBUIÇÕES ESPERADAS**	42
6.1	**Contribuições**	42
7	**CRONOGRAMA**	43
	REFERÊNCIAS	44

1 INTRODUÇÃO

1.1 Considerações Iniciais

Dentro de uma estrutura de produção industrial, é fundamental que os procedimentos associados às diferentes etapas do processo produtivo sejam claramente definidos e devidamente integrados. A complexidade dos sistemas produtivos modernos exige que as decisões relacionadas à produção, preparação e estocagem considerem, de forma simultânea, todas as variáveis relevantes do processo, de modo a minimizar o custo total do sistema e assegurar o atendimento da demanda ao longo do horizonte de planejamento.

Nesse contexto, destaca-se o Problema de Dimensionamento de Lotes (PDL), amplamente estudado no âmbito do planejamento e controle da produção, cujo objetivo é determinar, ao longo de um horizonte finito, em quais períodos produzir e em que quantidades, de modo a atender integralmente à demanda e minimizar custos de produção, preparação e estocagem. Trata-se de um problema de otimização intertemporal, no qual decisões tomadas em determinado período impactam diretamente períodos subsequentes.

Quando há a integração entre decisões de produção, remanufatura e gestão de estoques dá origem ao Problema de Dimensionamento de Lotes com Retorno (PDLR). Nesse problema, as decisões são fortemente interdependentes ao longo do tempo, uma vez que a quantidade de itens remanufaturáveis em determinado período depende diretamente dos retornos acumulados em períodos anteriores, influenciando a necessidade de produção futura Santos *et al.* (2025). A presença de estoques distintos confere ao problema uma estrutura temporal rica, caracterizada por balanços de fluxo intertemporais e custos fixos e variáveis.

Do ponto de vista da modelagem matemática, o PDLR é comumente formulado como um Problema de Programação Linear Inteira Mista (MILP), no qual variáveis contínuas e inteiras representam quantidades produzidas, remanufaturadas e estocadas, bem como decisões de ativação de produção e remanufatura. Contudo, à medida que o horizonte de planejamento se amplia, tais formulações podem tornar-se computacionalmente onerosas.

Diante dessa limitação, abordagens heurísticas e metaheurísticas têm sido amplamente empregadas na literatura como alternativas para obtenção de soluções de boa qualidade em tempo computacional reduzido (SANTOS *et al.*, 2025; BARBOSA, 2025). Embora tais métodos não garantam otimalidade, frequentemente apresentam desempenho satisfatório em instâncias de maior porte, especialmente em problemas com forte estrutura intertemporal.

Nesse contexto, os Diagramas de Decisão para Otimização (DDOs), ou simplesmente Diagrama de Decisões (DDs) surgem como uma abordagem promissora para problemas com forte estrutura temporal. Um DD pode ser definido como um grafo dirigido e acíclico que representa, de forma implícita, o conjunto de soluções viáveis de um problema cuja formulação esteja associada à Programação Dinâmica Oliveira (2025). Cada caminho da raiz até um nó terminal corresponde a uma solução viável do problema original, estabelecendo uma conexão natural entre DDOs e problemas de otimização discreta (OLIVEIRA, 2025).

1.2 Relevância e Justificativa

A crescente adoção de práticas de logística reversa tem transformado a forma como os sistemas produtivos são planejados e operados. Ao considerar a reinserção de produtos devolvidos no processo produtivo, a logística reversa amplia o escopo da produção industrial tradicional e impõe novos desafios ao planejamento da produção. Consequentemente, problemas clássicos, como o Problema de Dimensionamento de Lotes (PDL), passaram a incorporar decisões relacionadas à recuperação e remanufatura de produtos (DEKKER *et al.*, 2004).

No contexto do PDL com Retorno (PDLR), assume-se que um número conhecido de produtos usados retorna ao sistema em cada período do horizonte de planejamento. Embora esses itens não correspondam a uma demanda direta, eles podem ser remanufaturados e, uma vez recuperados, tornam-se funcionalmente equivalentes aos produtos novos, podendo atender à demanda ao longo do tempo (HELMRICH *et al.*, 2013). Essa característica confere ao PDLR maior aderência à realidade industrial, ao mesmo tempo em que aumenta significativamente sua complexidade computacional.

Do ponto de vista teórico, o PDLR pertence a uma classe de problemas de otimização com decisões intertemporais, custos fixos e estrutura de rede implícita, tornando-o particularmente atrativo para investigação. Apesar de sua relevância, ainda existem poucos trabalhos que exploram de forma sistemática abordagens baseadas em Diagramas de Decisão (DDs) aplicados ao dimensionamento de lotes com remanufatura, evidenciando uma lacuna na literatura.

Dessa forma, este trabalho contribui para o avanço do estado da arte no planejamento da produção com remanufatura, propondo uma abordagem inovadora que integra DDs e o PDLR, combinando modelagem exata e heurísticas para enfrentar a complexidade do problema.

1.3 Objetivos

1.3.1 Objetivo Geral

Investigar o uso de Diagramas de Decisão para Otimização como ferramenta de modelagem e solução para o Problema de Dimensionamento de Lotes com Retorno (PDLR), avaliando sua capacidade de representar o problema de forma exata, além de analisar o desempenho de estratégias heurísticas.

1.3.2 Objetivos Específicos

- Modelar o PDLR utilizando Programação Dinâmica;
- Construir Diagramas de Decisão para representação e análise do problema;
- Elaborar algoritmos exatos explorando a estrutura dos diagramas;
- Aplicar heurísticas do tipo Relax-and-Fix e Fix-and-Optimize;
- Testar computacionalmente os métodos propostos;
- Avaliar o desempenho e a qualidade das soluções obtidas em comparação com abordagens da literatura.

1.4 Organização do trabalho

Este trabalho está organizado da seguinte forma. O Capítulo 2 contempla a revisão de literatura, abordando a evolução do Problema de Dimensionamento de Lotes com Retorno, os principais paradigmas de modelagem e métodos de solução, além de uma síntese crítica dos trabalhos relacionados. No Capítulo 3 é descrito formalmente o Problema de Dimensionamento de Lotes com Retorno(PDLR), bem como sua formulação por meio de Programação Linear Inteira Mista (MILP). O Capítulo 4 apresenta os modelos, formulações e algoritmos propostos para o PDLR, incluindo a modelagem por Programação Dinâmica, o uso de Diagramas de Decisão para Otimização e heurísticas. O Capítulo 5 descreve os experimentos computacionais realizados, detalhando as características das instâncias e a configuração experimental adotada. Por fim, o Capítulo 6 apresenta as contribuições esperadas do estudo e suas possíveis implicações para a área.

2 REVISÃO DE LITERATURA

2.1 Estrutura e Evolução do Problema de Dimensionamento de Lotes com Retorno

O Problema de Dimensionamento de Lotes (PDL) constitui um dos modelos centrais da Pesquisa Operacional aplicada ao planejamento da produção. O trabalho seminal de Wagner e Whitin (1958) estabeleceu a formulação dinâmica multiperíodo sem restrições de capacidade, demonstrando que o problema pode ser resolvido de forma ótima por Programação Dinâmica em tempo polinomial. A principal contribuição desse modelo foi a exploração de propriedades estruturais da solução ótima, particularmente o caráter intertemporal das decisões de produção.

A partir desse modelo clássico, a literatura evoluiu incorporando restrições de capacidade, múltiplos itens, estruturas de custo dependentes do tempo e ambientes com maior nível de integração operacional. Conforme discutido por Wolsey (1998), tais extensões conduzem tipicamente a formulações em Programação Linear Inteira Mista (MILP), nas quais variáveis binárias de preparação (setup) são combinadas com variáveis contínuas de produção e estoque. Estudos como Heuvel (2006) analisam o impacto dessas extensões na estrutura poliedral do problema e na qualidade das relaxações lineares.

A incorporação de fluxos de retorno ao modelo clássico deu origem ao Problema de Dimensionamento de Lotes com Retorno (PDLR). Nesse contexto, decisões de produção e remanufatura passam a coexistir, introduzindo acoplamento estrutural entre fluxos direto e reverso. O modelo multiperíodo com retornos determinísticos foi formalizado por Teunter *et al.* (2006), que integraram explicitamente estoques de itens novos e retornados em um mesmo sistema de balanço.

Posteriormente, Helmrich *et al.* (2013) investigaram a complexidade estrutural do problema com remanufatura, evidenciando que o acoplamento intertemporal inviabiliza decomposições simples por período, característica presente no modelo clássico. De forma complementar, Piñeyro e Viera (2015) analisaram impactos estruturais da integração entre produção e remanufatura, destacando o aumento significativo da complexidade combinatória.

Em termos de formulação, o PDLR é tipicamente modelado como um MILP com variáveis binárias de ativação de produção e remanufatura, cujas restrições de balanço integram simultaneamente fluxos direto e reverso (CUNHA; MELO, 2016; SIFALERAS *et al.*, 2015). Diferentes escolhas de modelagem impactam diretamente a qualidade das relaxações lineares e, consequentemente, o desempenho computacional dos métodos exatos. Trabalhos recentes,

como Santos *et al.* (2025), reforçam que a estrutura da formulação exerce papel determinante na eficiência dos algoritmos empregados.

Embora a literatura apresente avanços consistentes na modelagem do PDLR, permanecem desafios relacionados ao crescimento do esforço computacional à medida que se ampliam o horizonte de planejamento e o nível de integração entre decisões.

2.2 Paradigmas de Modelagem e Métodos de Solução

As abordagens de resolução para o PDLR podem ser agrupadas em diferentes paradigmas de modelagem e solução, destacando-se formulações MILP, Programação Dinâmica, Diagramas de Decisão e heurísticas baseadas em decomposição temporal.

2.2.1 Formulações em Programação Linear Inteira Mista

A Programação Linear Inteira Mista constitui a principal abordagem exata para o PDLR. Formulações clássicas utilizam variáveis binárias de setup associadas à produção e à remanufatura, combinadas com variáveis contínuas de fluxo e estoque (CUNHA; MELO, 2016; SIFALERAS *et al.*, 2015). Conforme observado por Helmrich *et al.* (2013), a qualidade da relaxação linear é fortemente influenciada pela estrutura das restrições de balanço e pela forma de modelagem dos acoplamentos temporais.

Esforços de fortalecimento incluem reformulações estruturais e a incorporação de desigualdades válidas, visando reduzir o gap de relaxação e melhorar o desempenho de solucionadores comerciais (WOLSEY, 1998). Ainda assim, instâncias de grande porte permanecem desafiadoras do ponto de vista computacional.

2.2.2 Programação Dinâmica

A Programação Dinâmica preserva relevância especialmente em contextos sem restrições de capacidade, explorando explicitamente a estrutura temporal do problema, conforme estabelecido por Wagner e Whitin (1958). Entretanto, no PDLR, a presença de estoques distintos para itens novos e retornados amplia o espaço de estados, podendo levar a crescimento exponencial no número de combinações possíveis. Essa característica limita a aplicabilidade direta da abordagem em instâncias de maior porte.

2.2.3 Diagramas de Decisão

Diagramas de Decisão (DDs) emergem como alternativa promissora para representação compacta do espaço de soluções em problemas de otimização discreta. Bergman *et al.* (2016) estabeleceram fundamentos teóricos para o uso de DDs na modelagem de conjuntos viáveis de programas inteiros, destacando sua estrutura em camadas e sua capacidade de representar soluções por meio de caminhos em grafos acíclicos.

Abordagens baseadas em diagramas relaxados e restritos permitem a obtenção de limites duais e primais, viabilizando sua integração em esquemas de Branch-and-Bound (B&B) (HOEVE, 2020; SALEMI; DAVARNIA, 2023). No contexto do dimensionamento de lotes com retorno, aplicações ainda são incipientes, embora estudos como Santos *et al.* (2025) indiquem potencial significativo na integração entre modelagem estruturada e métodos exatos.

2.2.4 Heurísticas de Decomposição Temporal

Além dos métodos exatos, heurísticas baseadas em decomposição do horizonte de planejamento têm sido amplamente utilizadas para tratar instâncias de maior dimensão. Entre essas estratégias destacam-se as heurísticas Relax-and-Fix e Fix-and-Optimize.

A heurística Relax-and-Fix particiona o horizonte temporal em blocos, resolvendo iterativamente subproblemas nos quais parte das variáveis é tratada como inteira enquanto o restante é relaxado (TOLEDO *et al.*, 2015; SANTOS *et al.*, 2025). Essa estratégia reduz a dimensão dos subproblemas e permite a construção progressiva de soluções viáveis.

Por sua vez, a heurística Fix-and-Optimize parte de uma solução inicial e realiza refinamentos sucessivos por meio da reotimização de subconjuntos de variáveis, mantendo as demais fixadas (BARBOSA, 2025; SANTOS *et al.*, 2025). Tal abordagem explora a estrutura temporal do problema e possibilita melhorias iterativas com custo computacional controlado.

No contexto do PDLR, caracterizado por forte acoplamento intertemporal, tais heurísticas mostram-se particularmente relevantes, podendo ser integradas a formulações MILP fortalecidas ou combinadas com estratégias de ramificação (CUNHA; MELO, 2016).

Em síntese, embora a literatura apresente diferentes paradigmas de modelagem e solução para o PDLR, ainda há espaço para investigações comparativas quanto ao impacto estrutural das escolhas de modelagem, à qualidade das relaxações e à integração entre representações alternativas e estratégias heurísticas.

2.3 Síntese e Análise de Literatura

Após a revisão das bases conceituais que sustentam este trabalho, esta seção apresenta um levantamento dos principais estudos que aplicam tais técnicas ao PDL. A análise foca em identificar como a literatura lida com a integração de fluxos de retorno e remanufatura, bem como os métodos de solução predominantes.

Tabela 1 – Síntese da literatura sobre dimensionamento de lotes com retorno e métodos de solução

Referência	**Estrutura do Modelo**	**Retorno / Incerteza**	**Formulação**	**Contribuição Principal**
Wagner e Whitin (1958)	Item único, multiperíodo, sem capacidade	Não / Determinístico	Programação dinâmica	Fundamento teórico do dimensionamento dinâmico de lotes
Teunter et al. (2006)	Item único, multiperíodo, remanufatura	Sim / Determinístico	MIP + PD	Primeira extensão clássica com retornos explícitos
van den Heuvel (2006)	Item único, multiperíodo, remanufatura	Sim / Determinístico	Formulações estendidas	Análise estrutural e extensões do ELSP-R
Poles (2009)	Cadeia de suprimentos em ciclo fechado	Sim / Dinâmico	Dinâmica de sistemas	Avaliação sistêmica do impacto dos retornos
Schulz (2011)	Item único, multiperíodo	Sim / Determinístico	Heurística Silver–Meal	Heurística eficiente para grandes horizontes
Giglio e Paolucci (2014)	Produção e remanufatura integradas	Sim / Determinístico	MIP integrada	Integração explícita entre produção e remanufatura
Macedo et al. (2015)	Produção híbrida, custos e retornos estocásticos	Sim / Estocástico	Programação estocástica	Tratamento conjunto de múltiplas incertezas
Piñeyro e Viera (2015)	Item único, multiperíodo	Sim / Determinístico	Reformulação MIP	Algoritmo aprimorado e ganhos computacionais
Sifaleras et al. (2015)	Item único, multiperíodo	Sim / Determinístico	MIP	Metaheurística VNS para instâncias grandes
Cunha e Melo (2016)	Item único, multiperíodo	Sim / Determinístico	Comparação de MIP	Avaliação de formulações e desempenho computacional
Retel Helmrich et al. (2013)	Item único, multiperíodo	Sim / Determinístico	Formulações fortes	Complexidade computacional e limites teóricos
Arulselvan (2021)	Multiperíodo, demanda incerta	Sim / Estocástico	Prog. estocástica multiestágio	Modelagem realista com incerteza de demanda
Bergman et al. (2016)	MIP geral	—	Diagramas de decisão	Base teórica para otimização com DD
Salemi e Davarnia (2023)	MIP estruturado	—	DD-representável	Caracterização estrutural de MILPs
van Hoeve (2024)	Otimização combinatória	—	Diagramas de decisão	Formalização moderna e aplicações em PO
Santos, Cunha e Prata (2025)	PDLR, multiperíodo	Sim / Determinístico	MIP + heurísticas	Estado da arte nacional em PDLR

Fonte: Elaborado pela autora (2026)

A Tabela 1 consolida essa investigação, destacando as lacunas que motivam o uso de Diagramas de Decisão neste trabalho. A literatura sobre o PDLR apresenta uma evolução consistente tanto do ponto de vista da modelagem quanto dos métodos de solução. Partindo do modelo clássico de dimensionamento de lotes, proposto por Wagner e Whitin (1958) que estabelece a base da formulação multiperíodo resolvida por PD, extensões do problema surgiram incorporando fluxos de retorno e decisões de remanufatura, resultando em formulações MILP. A partir desse modelo clássico, a literatura evoluiu para contemplar contextos de logística reversa e remanufatura.

Observa-se ainda que métodos alternativos, como diagramas de decisão, têm sido explorados sobretudo em contextos gerais de otimização inteira, com aplicações ainda incipientes para o problema estudado. Essa constatação reforça a motivação para investigar abordagens que explorem a estrutura do PDLR de forma mais eficaz, combinando modelagem matemática rigorosa e estratégias avançadas de solução, de modo a ampliar a escalabilidade e a eficiência computacional em instâncias de maior porte.

3 DESCRIÇÃO DO PROBLEMA

3.1 Problema de Dimensionamento de Lotes com Retorno (PDLR)

O problema a ser estudado neste capítulo insere-se na classe de modelos integrados de produção e remanufatura com fluxos reversos, amplamente estudados na literatura de logística e planejamento da produção. A estrutura matemática adotada segue a linha clássica de modelos determinísticos de item único com horizonte finito, conforme apresentados em Teunter *et al.* (2006), Heuvel (2006), Schulz (2011), Piñeyro e Viera (2015).

3.1.1 Contextualização do Problema

Considera-se um sistema integrado de produção e remanufatura de um único item, operando ao longo de um horizonte de planejamento finito e discretizado no tempo. Em cada período, uma demanda externa deve ser atendida integralmente, podendo ser suprida tanto por itens recém-produzidos quanto por itens remanufaturados a partir de produtos usados que retornam ao sistema.

Produtos pós-consumo retornam ao sistema por meio de um fluxo reverso e são armazenados até serem eventualmente submetidos a processos de remanufatura. Assume-se que a remanufatura restaura os produtos retornados a uma condição funcionalmente equivalente à de produtos novos. Assim, itens produzidos e remanufaturados são considerados indistinguíveis do ponto de vista do atendimento da demanda.

A integração entre produção e remanufatura introduz um problema de decisão intertemporal, no qual escolhas realizadas em um período afetam a disponibilidade de produtos e retornos em períodos futuros. O objetivo do decisor é coordenar essas atividades de forma a minimizar o custo total de produção ao longo do horizonte de planejamento, respeitando as restrições de balanço de fluxo e de disponibilidade de retornos (ARULSELVAN, 2021).

3.1.2 Definição do Problema de Decisão

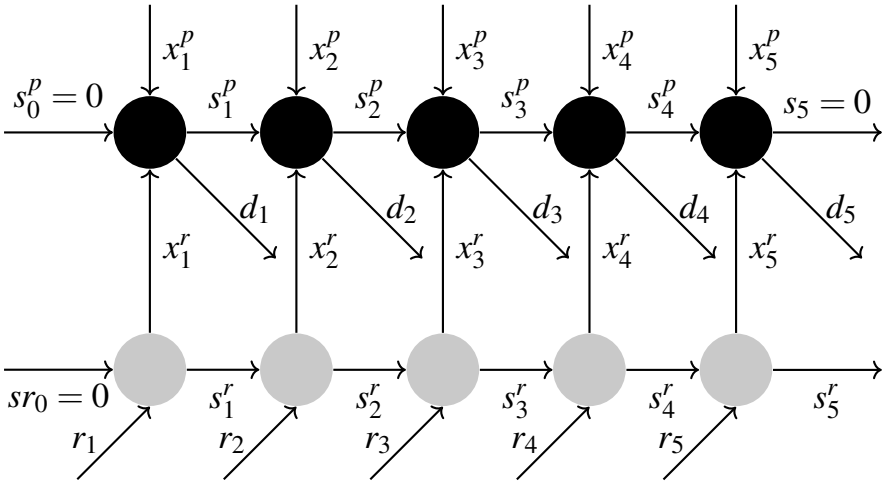
O problema consiste em determinar, para cada período t de um conjunto finito $T = \{1, 2, \ldots, n\}$, as quantidades de itens novos a serem produzidos, as quantidades de itens retornados a serem remanufaturados e os níveis de estoque a serem mantidos, de modo a satisfazer integralmente a demanda em todos os períodos.

Mais especificamente, as decisões incluem:

- A escolha dos períodos em que a produção de itens novos é ativada e a determinação das quantidades produzidas;
- A escolha dos períodos em que ocorre a remanufatura de produtos retornados e a determinação das quantidades processadas;
- O controle dos estoques de produtos disponíveis para atendimento da demanda e dos estoques de produtos retornados aguardando remanufatura.

O sistema está sujeito a custos fixos associados à ativação das atividades de produção e remanufatura, custos variáveis proporcionais às quantidades produzidas e remanufaturadas, e custos de manutenção de estoque ao longo do tempo.

Figura 1 – Rede de conservação de fluxo do PDLR



Fonte: Santos *et al.* (2025)

A Figura 1 apresenta o esquema de funcionamento do modelo PDLR, representado por um grafo dirigido. Neste grafo, os nós superiores (em preto) correspondem ao fluxo de itens produzidos e suprimento da demanda em cada período, enquanto os nós inferiores (em cinza) representam o processo de retorno de itens. As arestas direcionadas indicam a dinâmica entre as variáveis de decisão: x_t^p designa a produção em determinado período r_t corresponde à quantidade de produtos retornados, d_t refere-se à demanda a ser satisfeita, s_t^p e s_t^r denotam os estoques de produtos novos e recuperados, respectivamente, e x_t^r representa o fluxo de itens destinados à recuperação. Dessa forma, a estrutura acima exemplifica de maneira clara as interações entre produção, estoque, demanda e recuperação de itens, que são indispensáveis para a formulação matemática do problema de dimensionamento de lotes com recuperação.

3.2 Formulação via Programação Linear Inteira Mista (MILP)

Com base em Sifaleras *et al.* (2015), Cunha e Melo (2016) e Santos *et al.* (2025), apresenta-se a formulação matemática do PDLR.

Seja $T = \{1, \ldots, n\}$ o conjunto de períodos do horizonte de planejamento. Em cada período $t \in T$, existe uma demanda d_t a ser atendida, bem como custos associados à manufatura, remanufatura e estocagem ao menor custo possível, respeitando as restrições de estoque e a disponibilidade de retornos.

3.2.1 Variáveis de Decisão

- x_t^p: quantidade de itens manufaturados no período t;
- x_t^r: quantidade de itens remanufaturados no período t;
- y_t^p: variável binária que indica a abertura da manufatura no período t;
- y_t^r: variável binária que indica a abertura da remanufatura no período t.
- s_t^p: estoque de itens manufaturados ao final do período t;
- s_t^r: estoque de itens retornados não remanufaturados ao final do período t.

3.2.2 Parâmetros

- d_t: demanda no período t;
- r_t: quantidade de itens retornados no período t;
- p_t^p: custo unitário de manufatura no período t;
- p_t^r: custo unitário de remanufatura no período t;
- f_t^p: custo fixo de setup da manufatura no período t;
- f_t^r: custo fixo de setup da remanufatura no período t;
- h_t^p: custo unitário de estocagem de produtos;
- h_t^r: custo unitário de estocagem de retornos.
- h_t^r: custo unitário de estocagem de retornos.

3.2.3 Modelagem Matemática

$$\min \quad \sum_{t\in T}\left(h_t^p s_t^p + p_t^p x_t^p + f_t^p y_t^p\right) + \sum_{t\in T}\left(h_t^r s_t^r + p_t^r x_t^r + f_t^r y_t^r\right) \tag{3.1}$$

$$\text{sujeito a} \quad s_{t-1}^p + x_t^p + x_t^r = d_t + s_t^p, \qquad \forall t \in T, \tag{3.2}$$

$$s_{t-1}^r + r_t = x_t^r + s_t^r, \qquad \forall t \in T, \tag{3.3}$$

$$x_t^p \leq \left(\sum_{j=t}^{n} d_j\right) y_t^p, \qquad \forall t \in T, \tag{3.4}$$

$$x_t^r \leq \min\left\{\sum_{i=1}^{t} r_i,\ \sum_{j=t}^{n} d_j\right\} y_t^r, \qquad \forall t \in T, \tag{3.5}$$

$$s_0^p = 0, \quad s_n^p = 0, \quad s_0^r = 0, \tag{3.6}$$

$$x_t^p, x_t^r, s_t^p, s_t^r \geq 0, \qquad \forall t \in T, \tag{3.7}$$

$$y_t^p, y_t^r \in \{0,1\}, \qquad \forall t \in T. \tag{3.8}$$

A função objetivo apresentada na Equação (3.1) busca minimizar o custo total ao longo do horizonte de planejamento, composto pelos custos de manutenção de estoque, produção e preparação tanto para itens novos quanto para itens remanufaturados. A restrição (3.2) representa o balanço de estoque do produto novo, garantindo que o estoque disponível no período anterior, somado às quantidades produzidas e remanufaturadas no período atual, seja suficiente para atender à demanda e compor o estoque final. A restrição (3.3) descreve o balanço de estoque dos itens retornados, assegurando que a quantidade disponível de retornos, acrescida do estoque remanescente do período anterior, seja alocada entre remanufatura e estoque final. As restrições (3.4) e (3.5) estabelecem a necessidade de ativação dos custos de preparação sempre que houver produção ou remanufatura, limitando as quantidades processadas por meio das variáveis binárias correspondentes. A restrição (3.6) impõe as condições iniciais e finais dos estoques, garantindo que o sistema inicie e finalize o horizonte de planejamento sem unidades armazenadas. A restrição (3.7) define a não negatividade das variáveis contínuas do modelo, enquanto a restrição (3.8) especifica o caráter binário das variáveis de decisão associadas aos setups de produção e remanufatura.

Se acrescentamos a formulação (3.1)-(3.8) a restrição

$$x_t^p + x_t^r \leq C \text{ para } t \in T \tag{3.9}$$

a versão capacitada do problema, denominado Problema de Dimensionamento de Lotes Capaci-

tado com Retorno (PDLCR).

4 ALGORITMOS PARA RESOLVER O PDLR

Este capítulo apresenta propostas de métodos para resolver o Problema de Dimensionamento de Lotes com Retorno (PDLR). Inicialmente, são descritas duas abordagens: a Programação Dinâmica (PD) e os Diagramas de Decisão para Otimização (DDOs). Embora sejam matematicamente equivalentes, diferem na forma de modelagem e na maneira como o problema é resolvido. Além disso, também são apresentadas as heurísticas Relax-and-Fix e Fix-and-Optimize, propostas com o objetivo de obter soluções viável para o problema.

4.1 Programação Dinâmica (PD)

A Programação Dinâmica modela o PDLR como um processo de decisão sequencial determinístico, no qual decisões são tomadas ao longo de um horizonte finito de planejamento. A metodologia apresentada a seguir foi pensada especificamente para este trabalho, com base em escritos clássicos da literatura como Bellman (1957), Cormen *et al.* (2009) e Piñeyro e Viera (2015).

4.1.1 Estágios de decisão

O horizonte de planejamento é dividido em períodos discretos $t = 1, 2, \ldots, n$ em que cada período corresponde a um estágio de decisão do problema.

4.1.2 Estado

O estado do sistema no início do período t é definido pelo vetor ,

$$(s^p_{t-1}, s^r_{t-1}), \tag{4.1}$$

onde:

- s^p_{t-1} representa o estoque de produtos manufaturados disponíveis no início do período t;
- s^r_{t-1} representa o estoque de itens retornados disponíveis para remanufatura no início do período t.

Essas variáveis de estado são exatamente as mesmas utilizadas na formulação (3.1) - (3.8).

4.1.3 Decisão

Dado o estado (s^p_{t-1}, s^r_{t-1}), a decisão no período t consiste em escolher:

$$(x^p_t, x^r_t), \tag{4.2}$$

onde:

- $x^p_t \geq 0$ é a quantidade de itens manufaturados no período t;
- $x^r_t \geq 0$ é a quantidade de itens remanufaturados no período t.

Essas decisões são equivalentes às variáveis contínuas da formulação (3.1) - (3.8).

4.1.4 Função de transição de estados

A evolução do sistema é descrita pelas equações de balanço de estoque:

$$s^p_t = s^p_{t-1} + x^p_t + x^r_t - d_t, \tag{4.3}$$

$$s^r_t = s^r_{t-1} + r_t - x^r_t, \tag{4.4}$$

com as restrições:

$$s^p_t \geq 0, \quad s^r_t \geq 0, \quad \forall t, \tag{4.5}$$

e condições de contorno:

$$s^p_0 = 0, \quad s^r_0 = 0, \quad s^p_n = 0. \tag{4.6}$$

4.1.5 Função de custo imediato

O custo incorrido no período t, ao tomar a decisão (x^p_t, x^r_t) no estado (s^p_{t-1}, s^r_{t-1}), é dado por:

$$c_t(s^p_{t-1}, s^r_{t-1}, x^p_t, x^r_t) = h^p_t s^p_t + h^r_t s^r_t + p^p_t x^p_t + p^r_t x^r_t + f^p_t \, \mathbb{I}_{(x^p_t > 0)} + f^r_t \, \mathbb{I}_{(x^r_t > 0)}, \tag{4.7}$$

onde $\mathbb{I}(\cdot)$ é a função indicadora, definida como:

$$\mathbb{I}(\text{condição}) = \begin{cases} 1, & \text{se a condição é satisfeita,} \\ 0, & \text{caso contrário.} \end{cases}$$

Essa representação é equivalente à utilização das variáveis binárias y^p_t e y^r_t da formulação (3.1) - (3.8) para a ativação dos custos fixos de setup.

4.1.6 Função objetivo e equação de Bellman

Define-se $V_t(s^p_{t-1}, s^r_{t-1})$ como o custo mínimo acumulado do período t até o final do horizonte de planejamento, a partir do estado (s^p_{t-1}, s^r_{t-1}). A equação de Bellman é dada por:

$$V_t(s^p_{t-1}, s^r_{t-1}) = \min_{x^p_t, x^r_t} \left\{ c_t(\cdot) + V_{t+1}(s^p_t, s^r_t) \right\}, \tag{4.8}$$

com condição terminal:

$$V_{n+1}(0, s^r_n) = 0. \tag{4.9}$$

4.1.7 Política de decisão

Uma política de decisão é definida como:

$$\pi = \{\pi_1, \pi_2, \ldots, \pi_n\}, \tag{4.10}$$

em que cada função π_t associa a cada estado viável (s^p_{t-1}, s^r_{t-1}) uma decisão (x^p_t, x^r_t).

A política ótima π^* minimiza o custo total ao longo do horizonte.

A partir da formulação em programação dinâmica apresentada, o algoritmo a seguir explicita o processo de cálculo da função valor ao longo dos estágios do problema. Cada etapa do algoritmo corresponde à avaliação das decisões admissíveis em um determinado estado, conforme definido no modelo matemático(4.1 - 4.10).

Algoritmo 1: Programação Dinâmica para o PDLR

Input: $\{d_t, r_t, h_t^p, h_t^r, p_t^p, p_t^r, f_t^p, f_t^r\}$para $t \in T$

Output: custo ótimo e política ótima

Definir estágios $t = 1, \ldots, n$;

Definir estados (s_{t-1}^p, s_{t-1}^r);

$V_{n+1}(0,0) \leftarrow 0$;

for $t \leftarrow n$ **to** 1 **do**

  foreach *estado viável* (s_{t-1}^p, s_{t-1}^r) **do**

    $V_t(s_{t-1}^p, s_{t-1}^r) \leftarrow +\infty$;

    foreach *decisão viável* (x_t^p, x_t^r) **do**

      $s_t^p \leftarrow s_{t-1}^p + x_t^p + x_t^r - d_t$;

      $s_t^r \leftarrow s_{t-1}^r + r_t - x_t^r$;

      calcular o custo imediato:

      $$c_t = h_t^p s_t^p + h_t^r s_t^r + p_t^p x_t^p + p_t^r x_t^r + f_t^p \mathbb{I}_{(x_t^p > 0)} + f_t^r \mathbb{I}_{(x_t^r > 0)}$$

      $\tilde{V} \leftarrow c_t + V_{t+1}(s_t^p, s_t^r)$;

      if $\tilde{V} < V_t(s_{t-1}^p, s_{t-1}^r)$ **then**

        $V_t(s_{t-1}^p, s_{t-1}^r) \leftarrow \tilde{V}$;

        armazenar a decisão ótima (x_t^p, x_t^r);

      end

      else if $\tilde{V} = V_t(s_{t-1}^p, s_{t-1}^r)$ **then**

        escolher a decisão segundo um critério predefinido;

      end

    end

  end

end

return $V_1(0,0)$;

Observa-se que o algoritmo reflete diretamente a estrutura do modelo matemático, explicitando as transições entre estados e o cálculo do custo associado a cada decisão. A recorrência definida garante que a solução obtida satisfaça todas as restrições do problema, bem como a otimalidade em relação à função objetivo considerada.

4.2 Diagrama de Decisão para Otimização (DDO)

As bases bibliográficas para o entendimento e desenvolvimento desta técnica foram Bergman *et al.* (2016), Hoeve (2024) Salemi e Davarnia (2023). A PD é a chave para entender esta abordagem apresentada via DDO.

4.2.1 Estrutura em camadas e estados

O diagrama é organizado em camadas indexadas por $t = 1, \ldots, n+1$, em que cada camada corresponde a um período do horizonte de planejamento. A camada t contém nós que representam os estados do sistema no início do período t, definidos por:

$$\mathscr{S}_t = \left\{ (s^p_{t-1}, s^r_{t-1}) \in \mathbb{R}^2_+ \right\}$$

onde:

- s^p_{t-1} é o estoque de produtos manufaturados ao final do período $t-1$;
- s^r_{t-1} é o estoque de itens retornados disponíveis para remanufatura.

O nó inicial do diagrama é dado por

$$(s^p_0, s^r_0) = (0,0),$$

e os nós terminais viáveis pertencem à camada $n+1$, satisfazendo a condição

$$s^p_n = 0,$$

em concordância com a restrição (3.6).

4.2.2 Decisões e arcos

A partir de um nó $(s^p_{t-1}, s^r_{t-1}) \in \mathscr{S}_t$, são consideradas decisões

$$(x^p_t, x^r_t) \in \mathbb{R}^2_+,$$

representando, respectivamente, as quantidades manufaturadas e remanufaturadas no período t. Cada decisão viável define um arco direcionado do nó (s^p_{t-1}, s^r_{t-1}) para um nó da camada seguinte (s^p_t, s^r_t), de acordo com as funções de transição de estado:

$$s^p_t = s^p_{t-1} + x^p_t + x^r_t - d_t, \tag{4.11}$$

$$s^r_t = s^r_{t-1} + r_t - x^r_t. \tag{4.12}$$

As decisões são consideradas viáveis se, e somente se, respeitarem implicitamente as restrições de atendimento à demanda, disponibilidade de retornos e não negatividade, as quais são equivalentes às restrições (3.2) e (3.3).

4.2.3 Peso dos arcos (função de custo)

A cada arco associado à decisão (x_t^p, x_t^r) no estado (s_{t-1}^p, s_{t-1}^r) atribui-se um custo

$c_t(s_{t-1}^p, s_{t-1}^r, x_t^p, x_t^r)$,

definido por:

$$c_t = p_t^p x_t^p + p_t^r x_t^r + h_t^p s_t^p + h_t^r s_t^r + f_t^p \mathbb{I}_{(x_t^p>0)} + f_t^r \mathbb{I}_{(x_t^r>0)}, \tag{4.13}$$

em que $\mathbb{I}(\cdot)$ é a função indicadora. Essa expressão é diretamente equivalente ao termo correspondente da função objetivo (3.1).

4.2.4 Fusão de nós (merge)

Os nós pertencentes à mesma camada t e associados ao mesmo estado (s_{t-1}^p, s_{t-1}^r) são fundidos em um único nó, mantendo-se apenas o menor custo acumulado até esse estado. Formalmente, para dois caminhos distintos que alcançam o mesmo estado (s_{t-1}^p, s_{t-1}^r), preserva-se o caminho com menor custo acumulado, de acordo com o princípio da otimalidade de Bellman. Essa operação não altera a solução ótima e reduz significativamente o tamanho do DD.

4.2.5 Formulação como problema de caminho mínimo

O DD define implicitamente um problema de caminho mínimo em um grafo acíclico por camadas. Seja $\mathscr{P}$ o conjunto de todos os caminhos viáveis do nó inicial $(0,0)$ até um nó terminal admissível na camada $n+1$. O problema resolvido pelo DD é dado por:

$$\min_{P \in \mathscr{P}} \sum_{t=1}^{n} c_t(s_{t-1}^p, s_{t-1}^r, x_t^p, x_t^r), \tag{4.14}$$

sendo cada caminho P associado a uma política de decisão factível para o PDLR.

Com base na formulação matemática do problema e na representação por DDOs, o algoritmo a seguir descreve o procedimento de construção do diagrama ao longo dos estágios. Cada camada do diagrama corresponde a um estágio do modelo, enquanto os arcos representam as decisões admissíveis e seus respectivos custos, conforme definidos na modelagem matemática.

Algoritmo 2: Diagramas de Decisão para o PDLR

Input: $\{d_t, r_t, h_t^p, h_t^r, p_t^p, p_t^r, f_t^p, f_t^r\}_{t=1}^n$

Output: custo ótimo e política ótima

Criar a camada inicial $L_1 \leftarrow \{(0,0)\}$

Inicializar $V_1(0,0) \leftarrow 0$

for $t \leftarrow 1$ **to** n **do**

  Criar camada vazia L_{t+1}

  foreach *estado* $(s_{t-1}^p, s_{t-1}^r) \in L_t$ **do**

    foreach *decisão viável* (x_t^p, x_t^r) **do**

      calcular o estado sucessor:

      $s_t^p \leftarrow s_{t-1}^p + x_t^p + x_t^r - d_t$

      $s_t^r \leftarrow s_{t-1}^r + r_t - x_t^r$

      calcular o custo do arco:

      $c_t = h_t^p s_t^p + h_t^r s_t^r + p_t^p x_t^p + p_t^r x_t^r + f_t^p \mathbb{I}_{(x_t^p > 0)} + f_t^r \mathbb{I}_{(x_t^r > 0)}$

      if $(s_t^p, s_t^r) \notin L_{t+1}$ **then**

        $V_{t+1}(s_t^p, s_t^r) \leftarrow V_t(s_{t-1}^p, s_{t-1}^r) + c_t$

        armazenar o predecessor e a decisão

        adicionar (s_t^p, s_t^r) a L_{t+1}

      end

      else

        if $V_t(s_{t-1}^p, s_{t-1}^r) + c_t < V_{t+1}(s_t^p, s_t^r)$ **then**

          atualizar $V_{t+1}(s_t^p, s_t^r)$

          atualizar o predecessor e a decisão

        end

      end

    end

  end

  aplicar operação de *merge* e redução de largura em L_{t+1}

end

Selecionar o nó $(0, s_n^r)$ ou $(0,0)$ de menor custo na última camada

Reconstruir a política ótima por retrocesso

return *custo ótimo e política ótima*

Observa-se que o algoritmo estabelece uma ligação direta entre a formulação matemática e a estrutura do diagrama de decisão, garantindo que apenas transições viáveis sejam consideradas. A avaliação dos caminhos no diagrama permite identificar a solução ótima do problema, em conforme a função objetivo e as restrições do modelo.

4.3 Matheurísticas

Esta seção descreve duas matheurísticas empregadas para resolução do problema PDLR. As abordagens apresentadas baseiam-se em estratégias de decomposição do problema original em subproblemas menores e mais simples de resolver, permitindo tratar instâncias de grande porte com maior eficiência computacional.

Serão discutidas duas matheurísticas:

- Relax and Fix
- Fix and Optimize

4.3.1 Relax and Fix

A matheurística Relax and Fix (RF) consiste em um procedimento iterativo baseado em métodos exatos (WOLSEY, 1998). Em cada iteração, o conjunto de variáveis é dividido em três subconjuntos:

1. variáveis tratadas como inteiras;
2. variáveis tratadas como fixadas;
3. variáveis tratadas como relaxadas.

O método inicia resolvendo um subproblema no qual apenas as variáveis pertencentes à primeira partição são consideradas inteiras, enquanto as demais são relaxadas. Após a obtenção da solução, os valores das variáveis inteiras são fixados e um novo subconjunto passa a ser tratado como inteiro. Esse procedimento é repetido sucessivamente até que todas as partições tenham sido processadas.Se o algoritmo encontrar uma solução viável em cada passo, todas as variáveis que deveriam ser inteiras terão assumido valores inteiros ou até que algum subproblema se torne inviável.(BARBOSA, 2025; SANTOS *et al.*, 2025).

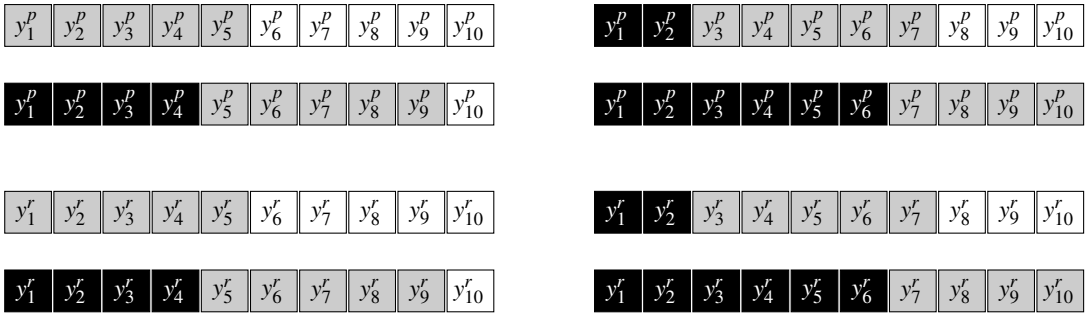
No problema em estudo existem dois conjuntos de variáveis binárias, y_t^p e y_t^r, definidos para $t = 1, \ldots, n$, os quais representam decisões de manufatura e remanufatura, respectivamente. A estratégia adotada segue a abordagem com partições sobrepostas proposta em

(SANTOS *et al.*, 2025; BARBOSA, 2025).

4.3.1.1 Funcionamento

A Figura 2 ilustra a execução da matheurística RF. Nela, as variáveis destacadas em preto representam com valores fixados; as variáveis em cinza correspondem àquelas tratadas como inteiras; e as variáveis em branco referem-se às variáveis tratadas como relaxadas.

Figura 2 – Exemplo de funcionamento do RF.



Fonte: Santos *et al.* (2025)

Na primeira iteração, as variáveis pertencentes ao bloco cinza são tratadas com inteiras e as pertecentes ao bloco branco são tratadas como relaxadas. Após a solução do subproblema, as variáveis do bloco preto são fixadas, do bloco cinza tratadas como inteiras e as do bloco bloco são consideradas como relaxadas. O processo prossegue até o final do horizonte de planejamento.

4.3.1.2 Geração das partições

As partições utilizadas são construídas conforme o Algoritmo 3. O procedimento recebe como entrada o número total de períodos n, o tamanho de cada partição e o número de períodos fixados entre partições consecutivas. Os algoritmos apresentados aqui são derivados do trabalho de Santos *et al.* (2025)

Algoritmo 3: Geração de Partições

Input: n, tamanho da partição T_{part}, deslocamento T_{fix}

Output: Conjunto de partições S

$index \leftarrow 1$

$S \leftarrow \emptyset$

while $index \leq n$ **do**

  if $index + T_{fix} > n$ **then**

    inserir $\{index, \ldots, n\}$ em S

    parar

  else

    inserir $\{index, \ldots, index + T_{part}\}$ em S

    $index \leftarrow index + T_{fix}$

  end

end

return S

4.3.1.3 Subproblema RF

O subproblema resolvido em cada iteração é apresentado no Algoritmo 4, evidenciando a dinâmica de fixação, relaxamento e atualização das variáveis ao longo das iterações.

Algoritmo 4: Subproblema Relax and Fix

Input: subconjunto atual

Output: solução parcial

for $i \leftarrow 1$ **to** n **do**

  if $i > \max(subset)$ **then**

    $y_i^p, y_i^r \in [0,1]$

  else if $i \in subset$ **then**

    $y_i^p, y_i^r \in \{0,1\}$

  else

    fixar y_i^p, y_i^r

  end

end

Resolver o modelo

return solução

4.3.2 Fix and Optimize

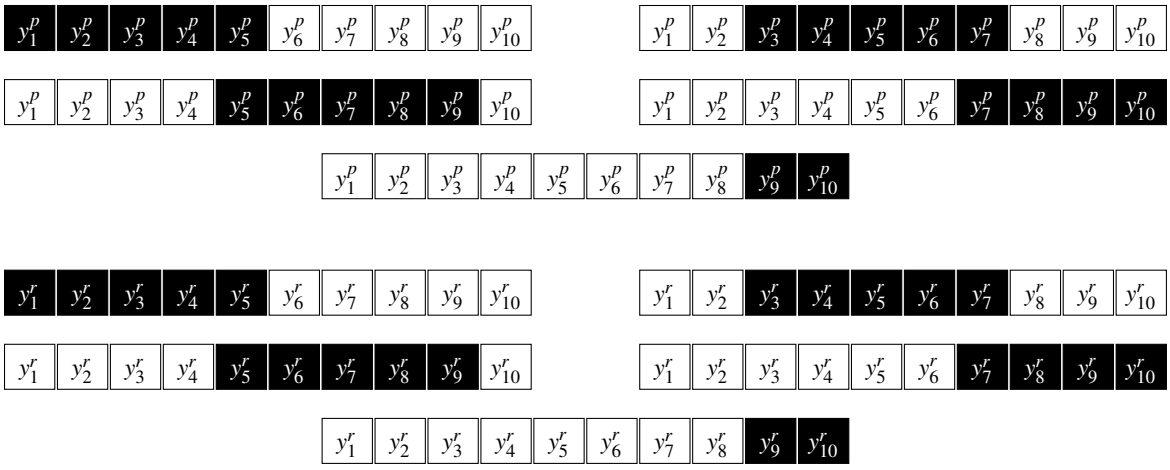
A matheurística Fix and Optimize (FOP) consiste em um procedimento de melhoria aplicado a uma solução viável inicial (SANTOS *et al.*, 2025; BARBOSA, 2025). O método baseia-se na ideia de selecionar um subconjunto de variáveis para otimização enquanto as demais tem valores fixadas.

O particionamento foi definido no conjunto dos períodos. A escolha do subconjunto e do tamanho das partições exerce influência direta tanto no tempo computacional quanto na qualidade das soluções obtidas (SANTOS *et al.*, 2025).

4.3.2.1 Funcionamento

A Figura 3 demonstra como a matheurística FOP realiza o deslocamento sequencial das posições, permitindo a exploração sistemática da solução. A figura 3 e os algoritmos 5 e 6 são propostos por Santos *et al.* (2025).

Figura 3 – Exemplo de funcionamento FOP.



Fonte: Adaptado de Santos *et al.* (2025)

Em cada iteração apenas as variáveis pertencentes ao subconjunto selecionado são tratadas como inteiras. Após a resolução do subproblema, a solução é atualizada e um novo subconjunto é escolhido.

4.3.2.2 Subproblema FOP

Algoritmo 5: Subproblema Fix and Optimize

Input: subconjunto atual

Output: nova solução

for $i \leftarrow 1$ **to** n **do**

  if $i \in subset$ **then**

    $y_i^p, y_i^r \in \{0,1\}$

  else

    fixar y_i, yr_i

  end

end

Resolver modelo

return solução

4.3.2.3 Procedimento geral

Algoritmo 6: Fix-and-Optimize

Input: solução inicial

Output: solução melhorada

Gerar conjunto de partições S

foreach $subset \in S$ **do**

  resolver subproblema

  atualizar solução

end

return melhor solução encontrada

4.3.3 Observação final

As matheurísticas RF e FOP são utilizadas de forma complementar. Enquanto a primeira constrói progressivamente uma solução viável ao longo do horizonte de planejamento, a segunda atua refinando essa solução por meio de otimizações locais sucessivas.

5 EXPERIMENTOS COMPUTACIONAIS

5.1 Instâncias

Neste trabalho, são consideradas 108 instâncias propostas por Sifaleras et al. (2015), todas definidas em um horizonte de planejamento composto por 52 períodos. As instâncias são geradas a partir de combinações de distribuições probabilísticas e conjuntos discretos de parâmetros, conforme descrito nas subseções seguintes.

5.1.1 Parâmetros

A demanda d_t e os retornos r_t são variáveis aleatórias com distribuição normal para $t \in \{1,2,\ldots,n\}$. A demanda possui média 100 e coeficiente de variação de 10% ou 20%, enquanto a média dos retornos pertence ao conjunto $\{30,50,70\}$, com coeficiente de variação de 10% ou 20%. Os demais parâmetros das instâncias são definidos por:

- $f_t^p, f_t^r \in \{200,500,2000\}$;
- $h_t^p = 1$ e $h_t^r \in \{0.2,0.5,0.8\}$;
- $p_t^p = p_t^r = 0$.

para $t \in \{1,2,\ldots,n\}$

5.1.2 Grupos de Instâncias

As instâncias são organizadas em grupos de acordo com os custos fixos de manufatura e remanufatura, conforme apresentado na Tabela 2.

Tabela 2 – Grupos de instâncias

Grupo	f_t^p	f_t^r
set01	200	200
set02	200	500
set03	200	2000
set04	500	200
set05	500	500
set06	500	2000
set07	2000	200
set08	2000	500
set09	2000	2000

Fonte: Adaptado de Sifaleras *et al.* (2015)

5.2 Ambiente Computacional

Os experimentos computacionais são executados em um computador com processador Intel(R) Core(TM) i5-6200U CPU @ 2.30GHz (2.40GHz), sistema operacional Windows. O resolvedor utilizado é o GUROBI 13.0.1, interfaceado com a linguagem Python.

Com relação a execução do exato pelo Gurobi foi definido o tempo limite de 3600 segundos, foi usado apenas uma thread nos experimentos e o solver foi configurado como default.

Com relação a matheurística foi definido o tempo limite de 3600 segundos para cada instância, foi usado apenas uma thread nos experimentos, e os seguintes valores para os parametros:

Variáveis de manufatura

- $T_{part} = 5$ para o Relax-and-Fix
- $T_{fix} = 2$ para o Relax-and-Fix
- $T_{part} = 6$ para o Fix-and-Optimizer
- $T_{fix} = 3$ para o Fix-and-Optimizer

Variáveis de remanufatura

- $T_{part} = 7$ para o Relax-and-Fix
- $T_{fix} = 2$ para o Relax-and-Fix
- $T_{part} = 8$ para o Fix-and-Optimizer
- $T_{fix} = 3$ para o Fix-and-Optimizer

5.3 Métricas de Avaliação

Para avaliar o desempenho das formulações estudadas, são consideradas métricas descritas na Tabela (3).

5.3.1 Solução viável para o PDLR

As Tabelas (4)-(8) apresentam o resumo dos resultados referente aos experimentos para o problema sem capacidade, com retorno e remanufatura. Os detalhes desses experimentos podem ser verificados no link <https://github.com/jesusossian/mmq_msc_andressa/blob/main/src/lsr_std/lsr_std_feasible.ipynb>.

A Tabela 4 mostra o resumo dos resultados dos experimentos do método exato usando o Gurobi para a formulação (3.1)-(3.8).

Tabela 3 – Métricas de avaliação

métrica	**descrição**
gap	Erro relativo médio
time	Tempo médio de execução pelo Gurobi
opt	Número de instâncias resolvidas à otimalidade
bound	Valor médio da relaxação linear do modelo encontrada pelo Gurobi
objval	Valor médio da melhor solução viável do modelo encontrada pelo Gurobi
nodes	Número médio de nós percorridos
sol_rf	Valor médio da solução obtida pelo método Relax-and-Fix
time_rf	Tempo médio de execução do método Relax-and-Fix
sol_fop	Valor médio da solução obtida pelo método Fix-and-Optimize
time_fop	Tempo médio de execução do método Fix-and-Optimize
time_math	Tempo médio de execução pela Matheurística

Fonte: Elaborado pela autora (2026)

Tabela 4 – Resultados do modelo exato com Gurobi

instance	bound	objval	gap	time	nodes	opt
set01	9674.50	9680.20	0.00	419.51	723210.67	11
set02	13530.83	13530.83	0.00	161.10	281019.25	12
set03	24430.29	24430.29	0.00	19.24	25153.83	12
set04	12843.64	12843.64	0.00	10.76	21227.25	12
set05	16826.48	16826.48	0.00	123.93	226197.33	12
set06	27706.90	27706.90	0.00	35.28	43102.75	12
set07	20334.82	20334.82	0.00	1.41	1795.92	12
set08	24661.75	24661.75	0.00	2.18	2259.50	12
set09	36360.38	36360.38	0.00	4.40	3224.17	12
resume	20707.73	20708.37	0.00	86.42	147465.63	107

A Tabela 5 mostra o resumo dos resultados dos experimentos da matheurística Relax-and-Fix e Fix-and-Optimizer.

A Tabela 6 mostra o resumo dos resultados com a primeira solução viável encontrada pelo Gurobi.

Na comparação da primeira solução viável encontrada pelo Gurobi com a solução viável encontrada pela matheurística foi verificado que a solução encontrada pela matheurística é melhor para todas as instâncias, 108, do benchmark.

A Tabela 7 mostra o resumo dos resultados com as melhores soluções viáveis encontradas pelo Gurobi em um tempo limite de 1.68 segundos. Esse tempo limite corresponde

Tabela 5 – Solução viável encontrada por RF+FOP

instance	sol_rf	time_rf	sol_fop	time_fop	time_math
set01	9856.98	0.53	9780.79	0.89	1.42
set02	13979.71	0.32	13671.12	0.41	0.73
set03	26252.88	0.21	25008.06	0.16	0.37
set04	13128.09	0.36	13009.17	0.49	0.85
set05	17366.63	0.34	17100.82	0.51	0.85
set06	29714.86	0.22	28358.95	0.17	0.39
set07	21004.72	0.21	20639.34	0.21	0.42
set08	25575.98	0.21	25174.50	0.25	0.45
set09	39140.93	0.19	37463.98	0.18	0.37
resume	21780.09	0.29	21134.08	0.36	0.65

Tabela 6 – Primeira solução viável encontrada pelo Gurobi

instance	objval	time
set01	14754.94	0.00
set02	26266.23	0.00
set03	81300.89	0.00
set04	22182.42	0.00
set05	32648.08	0.00
set06	88007.67	0.00
set07	58353.91	0.00
set08	69422.38	0.00
set09	122978.48	0.00

ao tempo máximo na execução da matheurística.

Tabela 7 – Melhor solução viável encontrada pelo Gurobi em 1.68 segundos

instance	bound	objval	gap	time	nodes	opt
set01	2892.48	9922.72	0.71	1.68	27745.08	0
set02	4864.08	13873.39	0.65	1.68	25964.83	0
set03	13043.70	24885.45	0.48	1.68	25552.00	0
set04	4606.03	13111.41	0.65	1.68	30005.42	0
set05	6131.10	17333.38	0.64	1.68	30811.92	0
set06	14290.37	28307.64	0.49	1.68	27246.50	0
set07	11550.27	20438.18	0.43	1.68	31210.08	0
set08	12843.74	25014.90	0.49	1.68	32393.92	0
set09	19246.84	37127.57	0.48	1.68	31872.25	0

Na comparação da solução viável encontrada pelo Gurobi com o tempo limite 1.68 segundos com a solução viável encontrada pela matheurística foi verificado que a solução encontrada pela matheurística é melhor para 54 instâncias do benchmark.

A Tabela 8 mostra o resumo dos resultados com as melhores soluções viáveis

encontradas pelo Gurobi em um tempo limite de 0.65 segundos. Esse tempo corresponde ao tempo médio na execução da matheurística.

Tabela 8 – Melhor solução viável encontrada pelo Gurobi em 0.65 segundos

instance	bound	objval	gap	time	nodes	opt
set01	2672.18	10093.11	0.74	0.65	9780.08	0
set02	4457.50	13965.78	0.68	0.65	8740.58	0
set03	11920.46	25093.47	0.53	0.65	8350.58	0
set04	4257.10	13270.47	0.68	0.65	9030.25	0
set05	5683.68	17507.64	0.68	0.65	9517.17	0
set06	13244.69	28544.02	0.54	0.65	8968.92	0
set07	10490.24	20525.81	0.48	0.65	8602.17	0
set08	11809.15	25148.85	0.53	0.65	8943.08	0
set09	18123.23	37220.49	0.51	0.65	9590.00	0

Na comparação da solução viável encontrada pelo Gurobi com o tempo limite 0.65 segundos com a solução viável encontrada pela matheurśitica foi verificado que a solução encontrada pela matheurística é melhor para 74 instâncias do benchmark.

5.3.2 Solução viável para o PDLR com capacidade

As Tabelas (9)-(13) apresentam o resumo dos resultados referente aos experimentos para o PDLR com capacidade. Os detalhes desses experimentos podem ser verificados no link <https://github.com/jesusossian/mmq_msc_andressa/blob/main/src/clsr_std/clsr_std_feasible.ipynb>.

A Tabela 9 mostra o resumo dos resultados dos experimentos do método exato usando o Gurobi para a formulação (3.1)-(3.8) com a restrição (3.9).

Tabela 9 – Resultados do modelo exato com Gurobi

instance	bound	objval	gap	time	nodes	opt
set01	10636.11	10641.49	0.00	990.13	1442878.42	11
set02	17190.73	17222.92	0.00	1831.62	2060173.67	9
set03	48099.39	48173.38	0.00	2456.42	2593639.17	6
set04	14875.52	14875.52	0.00	155.64	214424.08	12
set05	21784.58	21815.98	0.00	1598.68	1656838.33	9
set06	52746.64	52787.82	0.00	1944.77	1901926.92	9
set07	27721.94	27721.94	0.00	2.25	4031.67	12
set08	36906.26	36906.27	0.00	13.91	21119.75	12
set09	72747.59	72865.03	0.00	1414.60	1913768.83	9
resume	33634.31	33667.82	0.00	1156.45	1312088.98	89

A Tabela 10 mostra o resumo dos resultados dos experimentos da matheurística.

Tabela 10 – Melhor solução viável encontrada pelo RF+FOP

instance	sol_rf	time_rf	sol_fop	time_fop	time_total
set01	10750.78	0.36	10695.61	0.25	0.61
set02	17400.32	0.32	17340.15	0.24	0.57
set03	48494.73	0.32	48315.78	0.23	0.56
set04	15619.61	0.25	15010.42	0.20	0.45
set05	22638.51	0.26	22237.27	0.18	0.45
set06	53523.82	0.24	53164.47	0.19	0.43
set07	32192.93	0.15	27965.20	0.14	0.29
set08	41803.39	0.16	37162.18	0.13	0.28
set09	79636.47	0.17	76799.63	0.13	0.29
resume	35784.51	0.25	34298.97	0.19	0.44

A Tabela 11 mostra o resumo dos resultados com a primeira solução viável encontrada pelo Gurobi.

Tabela 11 – Primeira solução viável encontrada pelo solver

instance	objval	time
set01	14809.66	0.00
set02	26279.88	0.00
set03	80850.77	0.00
set04	22286.62	0.00
set05	32880.77	0.00
set06	88062.52	0.00
set07	58982.24	0.00
set08	69102.01	0.00
set09	122652.12	0.00

Na comparação da primeira solução viável encontrada pelo Gurobi com a solução viável encontrada pela matheurística foi verificado que a solução encontrada pela matheurística é melhor para todas as instâncias, 108, do benchmark.

A Tabela 7 mostra o resumo dos resultados com as melhores soluções viáveis encontradas pelo Gurobi em um tempo limite de 0.72 segundos. Esse tempo limite corresponde ao tempo máximo na execução da matheurística.

Na comparação da solução viável encontrada pelo Gurobi com o tempo limite 0.72 segundos com a solução viável encontrada pela matheurística foi verificado que a solução encontrada pela matheurística é melhor para 75 instâncias do benchmark.

A Tabela 8 mostra o resumo dos resultados com as melhores soluções viáveis

Tabela 12 – Melhor solução viável encontrada pelo Gurobi em 0.72 segundos

instance	bound	objval	gap	time	nodes	opt
set01	10245.66	10900.56	0.06	0.72	600.17	0
set02	16577.26	17748.74	0.07	0.72	617.83	0
set03	46618.20	49169.14	0.05	0.72	603.08	0
set04	14426.08	15220.58	0.05	0.72	618.42	0
set05	20972.73	22682.55	0.08	0.72	595.67	0
set06	51388.43	54199.51	0.05	0.72	602.00	0
set07	27497.89	27822.47	0.01	0.50	682.92	4
set08	36398.87	37164.76	0.02	0.63	884.92	4
set09	71442.55	74569.47	0.04	0.72	615.33	0

encontradas pelo Gurobi em um tempo limite de 0.44 segundos. Esse tempo corresponde ao tempo médio na execução da matheurística.

Tabela 13 – Melhor solução viável encontrada pelo Gurobi em 0.44 segundos

instance	bound	objval	gap	time	nodes	opt
set01	10180.63	10907.89	0.07	0.44	572.50	0
set02	16518.29	17775.27	0.07	0.44	575.25	0
set03	46522.48	49169.22	0.06	0.44	573.92	0
set04	14338.55	15229.62	0.06	0.44	585.75	0
set05	20892.88	22685.30	0.08	0.44	565.83	0
set06	51250.18	54272.20	0.06	0.44	564.25	0
set07	27441.19	27893.56	0.01	0.31	502.25	4
set08	36343.70	37175.34	0.02	0.42	697.25	1
set09	71323.12	74657.79	0.05	0.44	578.33	0

Na comparação da solução viável encontrada pelo Gurobi com o tempo limite 0.44 segundos com a solução viável encontrada pela matheurística foi verificado que a solução encontrada pela matheurística é melhor para 77 instâncias do benchmark.

6 CONTRIBUIÇÕES ESPERADAS

6.1 Contribuições

Espera-se que este trabalho contribua para o avanço do estudo do Problema de Dimensionamento de Lotes com Retorno (PDLR) sob diferentes perspectivas metodológicas e computacionais. As principais contribuições previstas são descritas a seguir.

Contribuições científicas

- Desenvolvimento de métodos baseados em Programação Dinâmica e Diagramas de Decisão, evidenciando formalmente a equivalência conceitual entre essas abordagens de modelagem e solução.
- Realização de análise computacional comparativa entre os métodos propostos.

Impacto esperado

- Avanço metodológico na literatura relacionada ao PDLR.
- Disponibilização de um conjunto de instâncias que poderá servir como benchmark para estudos posteriores.
- Fornecimento de subsídios teóricos e computacionais para o desenvolvimento de algoritmos especializados para problemas de dimensionamento de lotes com retornos.

Disseminação científica

Pretende-se submeter e publicar os resultados obtidos em periódicos e eventos científicos relevantes da área de Otimização, Pesquisa Operacional e Ciência de Dados, contribuindo para a difusão do conhecimento produzido e para o fortalecimento da pesquisa na temática abordada.

7 CRONOGRAMA

Quadro 1 – Cronograma de execução do trabalho

Etapas	2026								
	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Pesquisa sobre o tema	X	X	X	X					
Implementações	X	X	X	X	X				
Execução de experimentos			X	X	X	X	X		
Escrita do texto da dissertação	X	X	X	X	X	X	X	X	
Defesa									X

REFERÊNCIAS

ARULSELVAN, A. A multi-stage stochastic programming approach for the lot-sizing problem with remanufacturing. **International Journal of Production Research**, v. 59, n. 15, p. 4563–4580, 2021.

BARBOSA, F. A. Trabalho de Conclusão de Curso (Graduação em Matemática Industrial), **Uma nova abordagem de métodos heurísticos para o problema de dimensionamento de lotes capacitado com retorno**. Fortaleza: [s.n.], 2025. Centro de Ciências, Departamento de Estatística e Matemática Aplicada.

BELLMAN, R. **Dynamic Programming**. Princeton: Princeton University Press, 1957.

BERGMAN, D.; CIRE, A. A.; HOEVE, W.-J. van; HOOKER, J. N. **Decision Diagrams for Optimization**. Cham: Springer, 2016.

CORMEN, T. H.; LEISERSON, C. E.; RIVEST, R. L.; STEIN, C. **Introduction to Algorithms**. Cambridge: MIT Press, 2009.

CUNHA, J. O.; MELO, R. A. A computational comparison of formulations for the economic lot-sizing with remanufacturing. **Computers & Industrial Engineering**, v. 92, p. 72–81, 2016.

DEKKER, R. *et al.* (Ed.). **Reverse Logistics: Quantitative Models for Closed-Loop Supply Chains**. Berlin: Springer, 2004.

HELMRICH, M. J. R. *et al.* Economic lot-sizing with remanufacturing. **IIE Transactions**, v. 46, n. 1, p. 67–86, 2013.

HEUVEL, W. van den. **The economic lot-sizing problem**. Tese (Doutorado) — Erasmus University Rotterdam, 2006.

HOEVE, W.-J. van. An introduction to decision diagrams for optimization. In: **Tutorials in Operations Research: Emerging Optimization Methods and Applications**. INFORMS, 2020. p. 1–25. Disponível em: <https://doi.org/10.1287/educ.2020.0210>.

HOEVE, W.-J. van. An introduction to decision diagrams for optimization. In: **Tutorials in Operations Research**. Catonsville: INFORMS, 2024. p. 1–29.

OLIVEIRA, D. P. **Análise de heurísticas no método de Branch-and-Bound baseado em diagramas de decisão**. Dissertação (Trabalho de Conclusão de Curso (Bacharelado em Matemática Industrial)) — Universidade Federal do Ceará, Fortaleza, 2025.

Piñeyro, P.; VIERA, O. The economic lot-sizing problem with remanufacturing. **Journal of Remanufacturing**, v. 5, n. 12, p. 1–13, 2015.

POCHET, Y.; WOLSEY, L. A. **Production Planning by Mixed Integer Programming**. New York: Springer Science & Business Media, 2006. (Springer Series in Operations Research and Financial Engineering).

SALEMI, H.; DAVARNIA, D. On the structure of decision diagram–representable mixed-integer programs. **Operations Research**, v. 71, n. 6, p. 1943–1959, 2023.

SANTOS, M. P.; CUNHA, J. O.; PRATA, B. A. Formulações e métodos heurísticos para o problema de dimensionamento de lotes com retorno. **Pesquisa Operacional para o Desenvolvimento**, v. 17, p. e250011, 2025.

SCHULZ, T. A new silver–meal based heuristic for dynamic lot sizing with returns. **International Journal of Production Research**, v. 49, n. 9, p. 2519–2533, 2011.

SIFALERAS, A.; KONSTANTARAS, I.; MLADENOVIć, N. Variable neighborhood search for the economic lot sizing problem with returns. **International Journal of Production Research**, v. 53, n. 4, p. 988–1004, 2015.

TEUNTER, R. H.; BAYINDIR, Z. P.; HEUVEL, W. van den. Dynamic lot sizing with product returns and remanufacturing. **International Journal of Production Research**, v. 44, n. 20, p. 4377–4400, 2006.

TOLEDO, C. F. M.; ARANTES, M. S.; HOSSOMI, M. Y. B.; FRANÇA, P. M.; AKARTUNALI, K. A relax-and-fix with fix-and-optimize heuristic applied to multi-level lot-sizing problems. In: . [S.l.]: Springer, 2015.

WAGNER, H. M.; WHITIN, T. M. Dynamic version of the economic lot size model. **Management Science**, v. 5, n. 1, p. 89–96, 1958.

WOLSEY, L. A. **Integer Programming**. New York: Wiley, 1998.